


03

Engenharia de Logs de Eventos e Qualidade de Dados

Um log de eventos é um artefato analítico projetado, não uma exportação bruta do banco de dados.

Dos sistemas de origem ao log de eventos



As decisões de mapeamento incluem:

- ▶ Qual alteração no banco de dados conta como evento de negócio?
- ▶ Como os registros são correlacionados em casos?
- ▶ Quais datas/horas e fusos horários são oficiais?
- ▶ Quais eventos de baixo nível devem ser abstraídos?

Seis armadilhas comuns de qualidade de dados

1. Eventos ausentes
2. Eventos duplicados
3. Ordenação incorreta
4. Granularidade mista
5. Identificadores de caso instáveis
6. Viés de seleção e extração

Hábito de diagnóstico

Para cada padrão surpreendente, pergunte: *Isto é comportamento do processo, do registro ou da extração?*

O teste da noção de caso

Uma noção de caso útil deve responder a três perguntas:

1. Os eventos agrupados pertencem à mesma instância do processo?
2. A sequência resultante possui início e fim significativos?
3. Ela apoia a decisão que a análise pretende orientar?

Pedido como caso

Adequado para lead tempo do cliente e conclusão do pedido.

Item como caso

Melhor para atendimento parcial e tratamento no nível do item.

Um relatório compacto de qualidade

Verificação	Evidência	Decisão / limitação
Compleitude dos casos	8,4% não possuem evento final	Excluir casos abertos do KPI de tempo de ciclo
Ordenação temporal	23 intervalos negativos	Corrigir o desvio conhecido do relógio; sinalizar o restante
Duplicatas	1,2% de duplicatas exatas	Remover com uma chave documentada
Significado da atividade Cobertura	“Update” possui 4 fontes Os dados começam em jan. de 2025	Separar pela semântica de negócio Não fazer afirmações sobre versões anteriores do processo


Ideia-chave Documentar exclusões faz parte do resultado, não é mera sobrecarga administrativa.

Faça o profiling antes de transformar

Nível	Perfil	Decisão que orienta
Evento	Valores ausentes, duplicatas, datas/horas	Corrigir, excluir ou reinterpretar
Caso	Comprimento, duração, completude	Limites e política para casos abertos
Atividade	Frequência, ciclo de vida, recursos	Abstração e filtragem
Variante	Cobertura, raridade, entropia	Estratégia de ruído e segmentação
Temporal	Volume, drift, sazonalidade	Janelas temporais e divisão de avaliação

Ideia-chave O profiling não é apenas descritivo. Ele determina quais transformações, modelos e desenhos de avaliação são defensáveis.

O flattening é uma escolha de modelagem



Flattening por pedido

- ▶ Eventos compartilhados dos itens convergem

Flattening por item

- ▶ Eventos compartilhados do pedido são duplicados

Manter objetos

- ▶ As relações permanecem explícitas

Discussão Qual noção de caso preserva o comportamento necessário à sua pergunta e quais frequências ela distorce?

04

Análise Exploratória de Processos

Construa um mapa das evidências antes de construir um modelo de processo.

Explorar em quatro níveis

Log

Casos, eventos,
período e
cobertura

Caso

Duração, número
de eventos e
resultados

Atividade


Frequência,
recursos e
temporalidade

Variante

Caminhos,
prevalência,
desempenho

Discussão Qual nível revelaria retrabalho? Qual revelaria uma lacuna sazonal de extração?

Um grafo diretamente-seguido



Um DFG resume a adjacência observada:

- ▶ Os nós são atividades; as arestas significam “diretamente seguido por”
- ▶ As contagens podem representar frequência ou desempenho
- ▶ Laços, escolhas e concorrência exigem interpretação cuidadosa

Variantes: úteis, mas fáceis de usar incorretamente

Posição	Variante	casos	Tempo mediano
1	Receber, Verificação, Aprovar, Ship	68%	2.1 d
2	Receber, Verificação, Clarify, Verificação, Ship	14%	5.8 d
3	Receber, Verificação, Rejeitar	8%	1.4 d
4+	17 other variants	10%	8.2 d

As variantes revelam

- ▶ Rotas dominantes
- ▶ Padrões de retrabalho
- ▶ Comportamento excepcional

As variantes podem ocultar

- ▶ Comportamento concorrente
- ▶ Diferenças de atributos
- ▶ Casos raros importantes

Uma variante depende da codificação do trace

Codificação	Representação do trace	As variantes distinguem
Fluxo de controle	Sequência de atividades	Diferenças de roteamento
Sensível ao ciclo de vida	Atividade + transição	Início, suspensão, retomada, conclusão
Sensível ao tempo	Atividade + faixa de duração	Regimes comportamentais e temporais
Sensível ao payload	Atividade + atributos selecionados	Coortes de contexto ou resultado
Aprendida	Embedding de sequência/payload	Similaridade além da igualdade exata

Ideia-chave As contagens de variantes não são propriedades apenas do log bruto. Elas são produzidas por uma codificação, uma regra de equivalência e um limiar de similaridade.

Faça o profiling do payload antes de usá-lo

Payload do evento

Informação transportada por um evento além do caso, da atividade e da dados/hora.

- ▶ Atributos estruturados e medições
- ▶ Texto, documentos, imagens, áudio e referências de sensores
- ▶ Contexto de recurso, custo, localização e produto

Discussão Use dimensões do payload somente quando servirem à pergunta analítica; caso contrário, podem fragmentar traces em variantes sem significado com apenas um caso.

Faça o profiling antes da codificação

- ▶ Disponibilidade no momento do evento
- ▶ Valores ausentes e cardinalidade
- ▶ Drift, semântica e cardinalidade
- ▶ Privacidade, proxies e vazamento de informação futura

Fronteira de Pareto para detecção de variantes



Configurações candidatas

Codificação, limiar de similaridade, corte de variantes raras e dimensões do payload.

Objetivos

Cobertura de casos, compactação, relevância para a decisão e estabilidade temporal.

Inspecione traces representativos antes de selecionar uma configuração não dominada.

Um perfil de prontidão para modelagem

Antes da descoberta ou predição, registre:

- ▶ Distribuições de casos e comprimentos de traces
- ▶ Cobertura de variantes e comportamento de cauda longa
- ▶ Desbalanceamento de classes e resultados
- ▶ Atributos ausentes e de alta cardinalidade
- ▶ Drift do processo e da população
- ▶ Casos abertos versus concluídos
- ▶ Datas/horas de observação e do rótulo
- ▶ Possível vazamento de informação futura

Entrega

Um relatório de prontidão de uma página: população utilizável, distorções conhecidas, escolha de representação, estratégia de divisão e informações excluídas.

Exploração com PM4Py

```
import pm4py

print(pm4py.get_start_activities(log))
print(pm4py.get_end_activities(log))

variants = pm4py.get_variants_as_tuples(log)
dfg, starts, ends = pm4py.discover_dfg(log)

filtered = pm4py.filter_case_performance(
    log,
    min_performance=5 * 24 * 60 * 60,
)
```

Tarefa de interpretação: compare casos comuns com casos lentos. Quais diferenças de caminho são explicações plausíveis e quais exigem mais evidências?