




Repositório do curso

Mineração de Processos

Dos Dados de Eventos aos Insights de Processo

Sylvio Barbon Junior | University of Trieste



O que este curso realmente aborda

Observar

Transforme registros operacionais em dados de eventos confiáveis.

Explicar

Revele caminhos, escolhas, atrasos, retrabalho e desvios.


Melhorar

Converta evidências em uma intervenção de processo testável.

Ideia-chave A mineração de processos conecta **dados** para **processo comportamento**. O diagrama não é o resultado; a explicação defensável é.

Repositório do curso: github.com/sbarbonjr/process_mining_course

O nosso curso



Fundamentos

- ▶ Questões de processo e semântica de eventos
- ▶ Qualidade de dados e análise exploratória
- ▶ Modelos comportamentais e descoberta

Aplicação

- ▶ Qualidade do modelo e conformidade
- ▶ Desempenho e perspectivas organizacionais
- ▶ Análise centrada em objetos e entrega

Modelo de funcionamento do curso

Cada unidade combina

- ▶ Conceitos e intuição visual
- ▶ Um exemplo aplicado de log de eventos
- ▶ Um laboratório com PM4Py
- ▶ Um breve desafio de interpretação

Ferramentas principais

Python, pandas, PM4Py, Jupyter, Graphviz,
Git

Discussão Qual processo você encontra toda semana que deixa um rastro digital?

01


Visão Orientada a Processos e Mineração de Processos

Comece pela questão operacional, não pelo algoritmo.

Um processo é comportamento ao longo do tempo


Um processo é composto por:

- ▶ **casos:** instâncias do processo
- ▶ **atividades:** passos do processo
- ▶ **eventos:** execuções gravadas das atividades
- ▶ **recursos:** pessoas ou sistemas envolvidos
- ▶ **resultados:** tempo, custo, qualidade, compliance



Ideia-chave Um modelo de processo é uma afirmação sobre comportamentos possíveis. Um log de eventos é evidência do comportamento observado.

Quatro perguntas, quatro ramos



Discovery

Revele o comportamento real.

Conformance Checking

compare o log e o modelo.

Process Enhancement

Adicione tempo, custo ou decisões.

Predictive Process Monitoring

Antecipe resultados, atrasos

Mineração de processos não é um painel

	Análise tradicional	Mineração de processos
Unidade	Execuções	Casos e eventos ordenados
Pergunta	Quantos?	Como o trabalho se desenvolveu?
Estrutura	Geralmente tabular	Sequencial, concorrente, cíclico
Saída	KPI ou previsão	Comportamento, desvio, desempenho
Risco	Contexto ignorado	Semântica enganosa de caso/evento

Discussão Um Key Performance Indicator (KPI) de entrega piorou. Que perguntas sobre a sequência você faria antes de recomendar uma mudança?

Estruture uma análise útil

1. **Decisão:** Que decisão esta análise deve apoiar?
2. **Escopo:** Onde o processo começa e termina?
3. **Caso:** O que constitui uma instância do processo?
4. **Evidência:** Quais sistemas registram os eventos relevantes?
5. **Successo:** Qual comportamento ou resultado deve mudar?

Exemplo

“Por que alguns pedidos estão atrasados?” com PM: “Quais caminhos, transferências e períodos de espera distinguem os pedidos entregues após a meta de cinco dias?”

02

Dados de Eventos e Semântica do Log de Eventos

A qualidade da análise começa pelo significado de um evento.

O log de eventos mínimo viável

Caso	Atividade	Data (hora)	Recurso	Valor
O-17	Receber pedido	09:02	Portal	480
O-17	Verificar crédito	09:16	Elena	480
O-18	Receber pedido	09:12	Portal	125
O-17	Aprovar pedido	10:03	Marco	480
O-18	Verificar crédito	10:24	Elena	125

ID do caso

Agrupa eventos relacionados.

Atividade


Nomeia o que aconteceu.

Data (timestamp)

Ordena os eventos no tempo.

Ideia-chave Recursos, custos, estados do ciclo de vida e atributos de negócio enriquecem a análise, mas não corrigem uma noção de caso incoerente.

De eventos a traces e variantes



Trace: a sequência ordenada de atividades de um caso.

Variante: um padrão distinto de trace compartilhado por casos.

Aqui: 3 casos, 2 variantes.

A semântica do ciclo de vida muda a resposta



Uma atividade pode emitir vários eventos

- ▶ Iniciar
- ▶ Suspender / retomar
- ▶ Concluir

Ideia-chave Sem informações do ciclo de vida, o tempo decorrido pode ser confundido com tempo de trabalho ativo.

Um primeiro log de eventos no PM4Py

```
import pandas as pd
import pm4py

events = pd.read_csv("orders.csv")
events["timestamp"] = pd.to_datetime(
    events["timestamp"], utc=True
)

events = pm4py.format_dataframe(
    events,
    case_id="case_id",
    activity_key="activity",
    timestamp_key="timestamp",
)

pm4py.write_xes(events, "orders.xes")
```


Antes de executar a descoberta: verifique identificadores, timestamp, ordenação, duplicatas e o significado dos eventos.

03

Engenharia de Logs de Eventos e Qualidade de Dados

Um log de eventos é um artefato analítico projetado, não uma exportação bruta do banco de dados.

Dos sistemas de origem ao log de eventos



As decisões de mapeamento incluem:

- ▶ Qual alteração no banco de dados conta como evento de negócio?
- ▶ Como os registros são correlacionados em casos?
- ▶ Quais datas/horas e fusos horários são oficiais?
- ▶ Quais eventos de baixo nível devem ser abstraídos?

Seis armadilhas comuns de qualidade de dados

1. Eventos ausentes
2. Eventos duplicados
3. Ordenação incorreta
4. Granularidade mista
5. Identificadores de caso instáveis
6. Viés de seleção e extração

Hábito de diagnóstico

Para cada padrão surpreendente, pergunte: *Isto é comportamento do processo, do registro ou da extração?*

O teste da noção de caso

Uma noção de caso útil deve responder a três perguntas:

1. Os eventos agrupados pertencem à mesma instância do processo?
2. A sequência resultante possui início e fim significativos?
3. Ela apoia a decisão que a análise pretende orientar?

Pedido como caso

Adequado para lead tempo do cliente e conclusão do pedido.

Item como caso

Melhor para atendimento parcial e tratamento no nível do item.

Um relatório compacto de qualidade

Verificação	Evidência	Decisão / limitação
Completude dos casos	8,4% não possuem evento final	Excluir casos abertos do KPI de tempo de ciclo
Ordenação temporal	23 intervalos negativos	Corrigir o desvio conhecido do relógio; sinalizar o restante
Duplicatas	1,2% de duplicatas exatas	Remover com uma chave documentada
Significado da atividade Cobertura	“Update” possui 4 fontes Os dados começam em jan. de 2025	Separar pela semântica de negócio Não fazer afirmações sobre versões anteriores do processo


Ideia-chave Documentar exclusões faz parte do resultado, não é mera sobrecarga administrativa.

Faça o profiling antes de transformar

Nível	Perfil	Decisão que orienta
Evento	Valores ausentes, duplicatas, datas/horas	Corrigir, excluir ou reinterpretar
Caso	Comprimento, duração, completude	Limites e política para casos abertos
Atividade	Frequência, ciclo de vida, recursos	Abstração e filtragem
Variante	Cobertura, raridade, entropia	Estratégia de ruído e segmentação
Temporal	Volume, drift, sazonalidade	Janelas temporais e divisão de avaliação

Ideia-chave O profiling não é apenas descritivo. Ele determina quais transformações, modelos e desenhos de avaliação são defensáveis.

O flattening é uma escolha de modelagem



Flattening por pedido

- ▶ Eventos compartilhados dos itens convergem

Flattening por item


- ▶ Eventos compartilhados do pedido são duplicados

Manter objetos

- ▶ As relações permanecem explícitas

Discussão Qual noção de caso preserva o comportamento necessário à sua pergunta e quais frequências ela distorce?

Flattening e encoding: duas camadas, duas decisões



Flattening

Decide **quais eventos pertencem ao mesmo caso**. Mais amplo, anterior: escolhe a noção de caso (pedido, item, remessa...) e cria convergência ou divergência antes de qualquer trace existir.

Encoding

Decide **como um caso já definido é representado** como trace: fluxo de controle, ciclo de vida, tempo ou payload. Mais fino, posterior: molda as variantes depois que os casos já existem.

Ideia-chave Ambas são escolhas de modelagem, não padrões neutros: o flattening

04

Análise Exploratória de Processos

Construa um mapa das evidências antes de construir um modelo de processo.

Explorar em quatro níveis

Log

Casos, eventos,
período e
cobertura

Caso

Duração, número
de eventos e
resultados

Atividade


Frequência,
recursos e
temporalidade

Variante

Caminhos,
prevalência,
desempenho

Discussão Qual nível revelaria retrabalho? Qual revelaria uma lacuna sazonal de extração?

Um grafo diretamente-seguido



Um DFG resume a adjacência observada:

- ▶ Os nós são atividades; as arestas significam “diretamente seguido por”
- ▶ As contagens podem representar frequência ou desempenho
- ▶ Laços, escolhas e concorrência exigem interpretação cuidadosa

Variantes: úteis, mas fáceis de usar incorretamente

Posição	Variante	casos	Tempo mediano
1	Receber, Verificação, Aprovar, Ship	68%	2.1 d
2	Receber, Verificação, Clarify, Verificação, Ship	14%	5.8 d
3	Receber, Verificação, Rejeitar	8%	1.4 d
4+	17 other variants	10%	8.2 d

As variantes revelam

- ▶ Rotas dominantes
- ▶ Padrões de retrabalho
- ▶ Comportamento excepcional

As variantes podem ocultar

- ▶ Comportamento concorrente
- ▶ Diferenças de atributos
- ▶ Casos raros importantes

Uma variante depende da codificação do trace

Codificação	Representação do trace	As variantes distinguem
Fluxo de controle	Sequência de atividades	Diferenças de roteamento
Sensível ao ciclo de vida	Atividade + transição	Início, suspensão, retomada, conclusão
Sensível ao tempo	Atividade + faixa de duração	Regimes comportamentais e temporais
Sensível ao payload	Atividade + atributos selecionados	Coortes de contexto ou resultado
Aprendida	Embedding de sequência/payload	Similaridade além da igualdade exata

Ideia-chave As contagens de variantes não são propriedades apenas do log bruto. Elas são produzidas por uma codificação, uma regra de equivalência e um limiar de similaridade.

Faça o profiling do payload antes de usá-lo

Payload do evento

Informação transportada por um evento além do caso, da atividade e da dados/hora.

- ▶ Atributos estruturados e medições
- ▶ Texto, documentos, imagens, áudio e referências de sensores
- ▶ Contexto de recurso, custo, localização e produto

Faça o profiling antes da codificação

- ▶ Disponibilidade no momento do evento
- ▶ Valores ausentes e cardinalidade
- ▶ Drift, semântica e cardinalidade
- ▶ Privacidade, proxies e vazamento de informação futura

Discussão Use dimensões do payload somente quando servirem à pergunta analítica; caso contrário, podem fragmentar traces em variantes sem significado com apenas um caso.

Fronteira de Pareto para detecção de variantes



Inspecione traces representativos antes de selecionar uma configuração não dominada.

Configurações candidatas

Codificação, limiar de similaridade, corte de variantes raras e dimensões do payload.

Objetivos

Cobertura de casos, compactação, relevância para a decisão e estabilidade temporal.

Um perfil de prontidão para modelagem

Antes da descoberta ou predição, registre:

- ▶ Distribuições de casos e comprimentos de traces
- ▶ Cobertura de variantes e comportamento de cauda longa
- ▶ Desbalanceamento de classes e resultados
- ▶ Atributos ausentes e de alta cardinalidade
- ▶ Drift do processo e da população
- ▶ Casos abertos versus concluídos
- ▶ Datas/horas de observação e do rótulo
- ▶ Possível vazamento de informação futura

Entrega

Um relatório de prontidão de uma página: população utilizável, distorções conhecidas, escolha de representação, estratégia de divisão e informações excluídas.

Exploração com PM4Py

```
import pm4py

print(pm4py.get_start_activities(log))
print(pm4py.get_end_activities(log))

variants = pm4py.get_variants_as_tuples(log)
dfg, starts, ends = pm4py.discover_dfg(log)

filtered = pm4py.filter_case_performance(
    log,
    min_performance=5 * 24 * 60 * 60,
)
```

Tarefa de interpretação: compare casos comuns com casos lentos. Quais diferenças de caminho são explicações plausíveis e quais exigem mais evidências?

05

Fundamentos de Modelagem de Processos

Representações diferentes respondem a perguntas diferentes.

Quatro blocos fundamentais de comportamento

Sequência

$A \rightarrow B$

Uma segue a outra.

Escolha

$A \rightarrow (B|C)$

Um ramo é selecionado.

Paralelo

$A \rightarrow (B \parallel C)$

Ambas ocorrem; a ordem varia.

Laço

$A \rightarrow B \rightarrow A$

O comportamento se repete.

Ideia-chave Um modelo útil deve distinguir escolha de concorrência e permitir repetição sem permitir tudo.


Um DFG não é um modelo de processo completo

Traces observados

$\langle A, B, C, D \rangle$


$\langle A, C, B, D \rangle$

As evidências sugerem que B e C podem ocorrer em paralelo.



O DFG também parece permitir alternância repetida entre B e C . Esse comportamento nunca foi observado.


Representações de modelos



DFG

Ponto forte: visão geral rápida e legível

Atenção a: sem semântica completa de execução



Árvore de processos

Ponto forte: estruturada e sound por construção


Atenção a: restringe a forma do modelo



Rede de Petri

Ponto forte: concorrência e replay precisos

Atenção a: mais difícil para não especialistas



BPMN

Ponto forte: notação de negócio familiar

Atenção a: a semântica varia conforme o uso


Discussão Qual representação você usaria para discutir com stakeholders? E para verificação de conformidade baseada em alinhamentos?

Escolha uma estratégia de modelagem

Finalidade	Estratégia	Representação	Ênfase
Explicar o fluxo	Descoberta estruturada	Árvore de processos / BPMN	Simplicidade, fitness
Auditar regras	Modelagem normativa	Rede de Petri / Declare	Soundness, diagnósticos
Explorar a complexidade	Descoberta sensível à frequência	DFG / rede heurística	Cobertura, legibilidade
Prever o estado	Modelo de estado ou prefixo	Transição/features	Generalização, utilidade
Comunicar	Simplificar e anotar	BPMN / DFG	Interpretabilidade

Ideia-chave Não existe “melhor modelo independente do contexto.” Declare a finalidade antes de selecionar o algoritmo, a representação e os critérios de qualidade.

Abstração antes do algoritmo



Estratégias úteis

- ▶ Agrupar eventos técnicos
- ▶ Separar populações do processo
- ▶ Decompor por ciclo de vida ou subprocesso

Prática

- ▶ Versionar cada mapeamento
- ▶ Comparar perfis antes e depois
- ▶ Manter um vínculo rastreável com o evento bruto

Soundness: todo caso pode terminar corretamente?

Para um modelo de fluxo de trabalho, geralmente desejamos:

- ▶ Um início e uma conclusão significativos
- ▶ Toda atividade modelada pode ocorrer
- ▶ Nenhum deadlock antes da conclusão
- ▶ Nenhum token ou trabalho residual após a conclusão

Por que isso importa


Um diagrama atraente ainda pode codificar comportamentos impossíveis ou incompletos. A semântica formal permite testar o modelo em vez de confiar em sua aparência.

06

Descoberta de Processos

Algoritmos de descoberta condensam o comportamento dos eventos em um modelo explicativo.

A descoberta exige equilíbrio



A descoberta depende

de:

- ▶ O log de eventos e seu nível de abstração
- ▶ As premissas comportamentais do algoritmo
- ▶ Limiares de ruído e frequência
- ▶ O uso pretendido do modelo resultante

Três famílias de descoberta

Alpha Miner

Usa relações de ordenação para inferir comportamentos causais, paralelos e de escolha.

Mais indicado como fundamento conceitual.

Heuristics Miner

Usa medidas de frequência e dependência para tolerar ruído.


Útil para modelos exploratórios.

Inductive Miner

Encontra recursivamente cortes de sequência, escolha, paralelismo e laço.


Produz modelos estruturados e sound.

Um experimento disciplinado de descoberta



1. Defina restrições e direções das métricas antes de ver os resultados.
2. Mantenha os dados de descoberta separados dos dados de avaliação final.
3. Mantenha todos os parâmetros e artefatos candidatos, não apenas o vencedor.
4. Inspecione atividades e arestas instáveis, não apenas pontuações agregadas.

Intuição da descoberta indutiva



Cortes candidatos:

Sequência



Escolha exclusiva



Paralelo



Laço



Ideia-chave O resultado é uma árvore de processos que pode ser traduzida em uma rede de Petri ou modelo BPMN.

Descoberta com PM4Py

```
import pm4py

# Structured discovery
tree = pm4py.discover_process_tree_inductive(
    log, noise_threshold=0.2
)
net, initial, final = pm4py.convert_to_petri_net(tree)

# Business-facing representation
bpmn = pm4py.convert_to_bpmn(tree)
pm4py.save_vis_bpmn(bpmn, "discovered_process.svg")
```

Experimento: varie o limiar de ruído. Registre quais comportamentos desaparecem, quais permanecem e se o modelo se torna mais útil.

07

Qualidade e Avaliação de Modelos

Nenhuma pontuação isolada informa se um modelo é adequado à sua finalidade.

As quatro dimensões de qualidade

Fitness

O modelo consegue reproduzir o comportamento observado?

Precisão

Ele evita permitir comportamentos não observados?

Generalização

Ele lida com comportamentos futuros plausíveis?

Simplicidade

As pessoas conseguem compreendê-lo e utilizá-lo?


Ideia-chave Fitness perfeito é trivial se o modelo permite todo trace possível. A qualidade emerge do compromisso entre as dimensões.

Construa um vetor de qualidade, não uma única pontuação

Dimensão	Exemplo de medida	Risco de interpretação
Fitness	Fitness por alinhamento/replay	Favorece modelos permissivos
Precisão	Precisão por escaping edges/alinhamento	Sensível à cobertura do log
Generalização	Replay em holdout, validação cruzada	Depende do desenho da divisão
Simplicidade	Nós, arcos e complexidade do fluxo de controle	Pequeno nem sempre é compreensível
Estabilidade	Frequência de arestas/relações por bootstrap	Pontuações agregadas podem ocultar instabilidade
Viabilidade	Soundness, tempo de execução, memória	Restrições rígidas, não preferências

Ideia-chave Registre a direção da métrica, o método de cálculo, a divisão dos dados e a incerteza de cada componente do vetor de qualidade.

Fitness e precisão atuam em direções opostas



O ponto “melhor” depende de o modelo servir à explicação, simulação, conformidade ou predição.

Por que uma média ponderada pode enganar

Suponha:

$$\text{score} = 0.4 \text{ fitness} + 0.4 \text{ precision} + 0.2 \text{ simplicidade}$$


O que isso oculta

- ▶ Um mínimo crítico pode ser violado
- ▶ Pesos diferentes invertem o ranking
- ▶ Compensar métricas pode ser inaceitável
- ▶ Escala e normalização alteram o resultado

Primeiro passo melhor

- ▶ Aplicar restrições rígidas de viabilidade
- ▶ Remover candidatos dominados
- ▶ Inspeccionar a fronteira de Pareto
- ▶ Adicionar preferências somente depois

Dominância e fronteira de Pareto



O candidato X domina Y quando:

- ▶ X não é pior em nenhum objetivo
- ▶ X é melhor em pelo menos um objetivo

A **fronteira de Pareto** contém candidatos que não são dominados por nenhum outro.

Ideia-chave Um ponto de joelho oferece um bom compromisso, mas é candidato à discussão, não um vencedor automático.

Seleção prática na fronteira de Pareto

1. **Primeiro, imponha restrições:** exija soundness, fitness mínimo e tempo de execução ou tamanho do modelo aceitável.
2. **Estime a incerteza:** faça bootstrap dos casos ou repita folds temporais; não confie em diferenças mínimas de pontuação.
3. **Inspecione a sensibilidade:** varie limiares, abstração de atividades e implementação das métricas.
4. **Revise a fronteira:** mostre todos os modelos não dominados e explique o que se ganha e perde entre candidatos adjacentes.
5. **Selecione com transparência:** use um ponto de joelho, regra lexicográfica ou utilidade dos stakeholders após conhecer a fronteira.
6. **Valide uma vez:** reporte a escolha final em dados holdout intocados.

Replay e alinhamentos

Replay baseado em tokens

Reproduz traces em uma rede de Petri e conta tokens ausentes, restantes, consumidos e produzidos.

Rápido e diagnóstico, mas pode mascarar alguns desvios.

Alinhamentos

Encontra uma correspondência de custo mínimo entre o comportamento do log e o modelo.

Mais preciso, porém computacionalmente mais caro.

Discussão Você avaliaria um modelo de conformidade e um modelo exploratório com a mesma tolerância a desvios? Por quê?


Avalie os candidatos

```
fitness = pm4py.fitness_alignments(  
    log, net, initial, final  
)  
precision = pm4py.precision_alignments(  
    log, net, initial, final  
)  
  
print(fitness["log_fitness"])  
print(precision)
```

Uma comparação defensável registra:

- ▶ Pontuações e tempo de execução
- ▶ Tamanho e legibilidade do modelo
- ▶ Desempenho em treinamento versus holdout
- ▶ Qual comportamento importa para a pergunta analítica

Um protocolo de avaliação defensável



- ▶ Regras de geração e candidatos excluídos
- ▶ Vetores completos de métricas com incerteza, não apenas o modelo selecionado
- ▶ Pertencimento à fronteira de Pareto e regra de decisão final
- ▶ Desempenho em holdout, instabilidade conhecida e uso pretendido do modelo

08

Verificação de Conformidade

Encontre a menor explicação significativa de como a realidade e o modelo diferem.

O que conta como não conformidade?

O modelo pode ser normativo

- ▶ Política
- ▶ Regulação
- ▶ Procedimento operacional padrão

Um desvio pode indicar risco.

O modelo pode ser descritivo

- ▶ Descoberta anterior
- ▶ Padrão operacional esperado
- ▶ Baseline de simulação

Um desvio pode indicar mudança.

Ideia-chave A conformidade identifica diferenças. O contexto do domínio determina se elas são prejudiciais, úteis ou apenas ausentes do modelo.

Lendo um alinhamento

Posição	1	2	3	4	5
Log	Receber	Verificação	Clarify	Aprovar	Ship
Modelar	Receber	Verificação	»	Aprovar	Ship
Movimento	síncrono	síncrono	log	síncrono	síncrono

Movimento síncrono

Evento e modelo concordam.

Movimento no log

Evento observado sem correspondência.

Movimento no modelo

Comportamento esperado não observado.

Dos desvios aos achados

1. **Localize:** Quais atividades, caminhos e casos apresentam desvios?
2. **Quantifique:** Quão frequentes, custosos ou atrasados são?
3. **Segmente:** Quais produtos, equipes ou períodos diferem?
4. **Validar:** O modelo está atualizado e os dados estão completos?
5. **Explicar:** Qual mecanismo operacional poderia produzir isso?

Achado sólido

“A revisão manual de crédito é ignorada em 7,3% dos pedidos de alto valor, concentrados em um canal após a versão de abril do sistema.”

Diagnósticos de alinhamento no PM4Py

```
alignments = pm4py.conformance_diagnostics_alignments(  
    log, net, initial, final  
)  
  
for result in alignments[:3]:  
    print(result["fitness"])  
    print(result["alignment"])
```

Saída do laboratório: uma tabela ordenada de desvios contendo padrão, casos afetados, frequência, impacto no desempenho e interpretação validada.

09

Desempenho e Aprimoramento de Processos

Um gargalo é um mecanismo, não apenas um número vermelho.

Decomponha o tempo decorrido



Tempo total de atravessamento

Do início à conclusão do caso.

Tempo de serviço

Tempo de trabalho ativo.

Tempo de espera

Tempo entre atividades.

Quatro sinais de gargalo

- ▶ Longa espera antes de uma atividade
- ▶ Fila crescente ao longo do tempo
- ▶ Retrabalho retornando à mesma atividade
- ▶ Excesso de transferências antes da conclusão

Não pare em

“A atividade X possui a maior duração média.”

Pergunte se o atraso decorre de capacidade, processamento em lote, política, informação ausente, priorização ou medição.

compare coortes, não apenas médias


Coorte	Tempo de ciclo mediano	Taxa de retrabalho	casos
Pedidos padrão	2.2 d	6%	4,180
Pedidos personalizados	6.8 d	29%	640
Personalizados + canal parceiro	9.4 d	41%	185

Hipótese de melhoria

Pedidos personalizados do canal parceiro chegam com especificações incompletas, gerando ciclos de esclarecimento. Um formulário estruturado de entrada deve reduzir retrabalho e espera.

Uma hipótese nomeia um mecanismo e prevê uma mudança mensurável.

Do insight à intervenção




Ideia-chave A mineração de processos apoia a melhoria ao restringir e testar explicações. Ela não estabelece causalidade por si só.

10

Análise Organizacional e Multidimensional

Processos são redes de coordenação, não apenas sequências de atividades.

Uma rede de transferência de trabalho



A análise de redes pode revelar:

- ▶ Transferências frequentes e ciclos de coordenação
- ▶ Papéis centrais ou sobrecarregados
- ▶ Questões de segregação de funções
- ▶ Diferenças entre a colaboração formal e a real

Combine perspectivas

Fluxo de controle

Qual caminho?

tempo

Quanto tempo?

Organização

Quem coordenou?

dados

Sob quais condições?

Exemplo de síntese

Os ciclos de esclarecimento são mais lentos quando os casos passam das vendas do parceiro para as operações centrais, especialmente em produtos personalizados com dimensões ausentes.

Do log de eventos às linhas para aprendizado de máquina



Linha no nível do caso

Um caso concluído, geralmente para análise retrospectiva do resultado.

Linha no nível do prefixo

Um caso observado até um ponto de predição, usado para monitoramento online.

Ideia-chave Defina o corte de observação antes de calcular qualquer feature ou rótulo.

Estratégias de codificação

Codificação	Representação	Ponto forte	Risco principal
Agregação	Contagens, durações, último valor	Baseline simples e sólido	Perde a ordem
Baseada em índice	Atividade/atributo por posição	Preserva a ordem inicial	Tabelas largas e esparsas
Sequência	Tokens ou embeddings aprendidos	Captura ordem e contexto	Demanda dados e computação
Processo-aware	Variante, estado, movimentos de alinhamento	Usa a estrutura do domínio	Viés dependente do modelo
Graph	Features do DFG/grafa de objetos	Captura relações	Validação complexa
Centrada em objetos	Features por tipo de objeto	Evita flattening prematuro	As escolhas de agregação permanecem

Discussão Comece com um baseline de agregação. Adicione uma codificação mais rica somente quando ela melhorar a utilidade na validação o bastante para justificar a complexidade.

A proveniência das features faz parte do modelo

Para cada feature, registre:

- ▶ Evento de origem ou atributo do objeto
- ▶ Regra de agregação e de valores ausentes
- ▶ Primeiro momento em que a feature está disponível
- ▶ População de casos/objetos à qual se aplica
- ▶ Parâmetros de pré-processamento ajustados e período de treinamento

Exemplos sensíveis ao processo

Contagem de retrabalho, tempo decorrido, atividade atual, prefixo da variante, custo de alinhamento, estado do modelo, número de transferências, objetos abertos e carga de trabalho na chegada.

Análise responsável de recursos

- ▶ Analise papéis ou equipes antes de indivíduos, quando possível
- ▶ Verifique carga de trabalho, complexidade dos casos e cobertura dos dados
- ▶ Evite ranquear pessoas com métricas de processo não validadas
- ▶ Distinga restrições do processo de desempenho individual
- ▶ Aplique controle de acesso, minimização e limitação de finalidade

Ideia-chave Dados de eventos refletem o sistema que atribui o trabalho. Raramente são uma medida isolada justa da contribuição individual.

Correlação é uma pista, não uma causa

Uma equipe pode parecer mais lenta porque recebe:

- ▶ Casos mais complexos
- ▶ Casos já atrasados em etapas anteriores
- ▶ Trabalho com dados de menor qualidade
- ▶ Casos que exigem controles adicionais

Discussão Quais dados adicionais ou desenho de estudo ajudariam a distinguir o efeito da equipe das diferenças no perfil dos casos?

11

Mineração de Processos Centrada em Objetos

Alguns processos não possuem um único identificador natural de caso.

O problema do flattening

Um pedido pode conter

- ▶ Vários itens
- ▶ Várias entregas
- ▶ Várias faturas
- ▶ Um ou mais pagamentos

Caso forçado por pedido


Eventos no nível do item podem ser duplicados no trace achatado.

Caso forçado por item

Eventos compartilhados de fatura e entrega podem ser duplicados.

Isso cria **convergência** e **divergência**: frequências enganosas e relações comportamentais aparentes.

Dados de eventos centrados em objetos



- ▶ Eventos ligados a um ou mais objetos tipados
- ▶ Relações entre objetos
- ▶ Relações qualificadas e atributos de objetos que mudam

Centrado em casos ou em objetos?

Situação	Caso-centric	Centrada em objetos
Uma instância de negócio estável	Muito adequada	Frequentemente desnecessária
Várias entidades interagindo	Distorce	Muito adequada
KPI estabelecido por caso	Direta	Exige escolhas de agregação
Ferramentas familiares	Maduras	Emergentes
Perguntas sobre relações	Limitada	Nativa

Ideia-chave A análise centrada em objetos não elimina escolhas de modelagem. Ela explicita as relações para tornar essas escolhas visíveis.

Features centradas em objetos sem flattening prematuro

Por tipo de objeto

- ▶ Contagens e estados do ciclo de vida
- ▶ Resumos de idade e tempo decorrido
- ▶ Objetos relacionados concluídos e abertos
- ▶ Cardinalidades das relações

No momento da predição

- ▶ Congele o grafo de objetos no corte
- ▶ Agregue somente objetos visíveis
- ▶ Preserve identificadores para divisões agrupadas
- ▶ Teste a sensibilidade às regras de agregação

Ideia-chave Faça o flattening tarde e explicitamente. O objeto-alvo e o momento da predição devem determinar quais relações se tornam features.

Inspecione um OCEL com PM4Py

```
import pm4py

ocel = pm4py.read_ocel2_json("order_management.jsonocel")

print(ocel.events.head())
print(ocel.objects.head())
print(ocel.relations.head())

ocdfg = pm4py.discover_ocdfg(ocel)
pm4py.save_vis_ocdfg(ocdfg, "object_centric.svg")
```


Comparação do laboratório: faça o flattening dos mesmos dados por pedido e por item. Quais frequências ou caminhos se tornam enganosos?

12

Projetos e Comunicação

Um projeto de mineração de processos tem sucesso quando a evidência muda uma decisão.

O ciclo de vida do projeto




O ciclo de vida é iterativo. A validação do domínio pode alterar o mapeamento de eventos, a noção de caso, o modelo, a métrica ou até a pergunta original.

Tarefas de monitoramento preditivo de processos

Pergunta	Formulação de ML	Exemplo de alvo	Baseline útil
O que acontece a seguir?	Classificação	Próxima atividade	Transição mais frequente
Quanto tempo resta?	Regressão/sobrevivência	Tempo restante	Mediana por estado atual
Como terminará?	Classificação	Atraso / rejeição	Modelo pela taxa-base
Isto é incomum?	Deteção de anomalias	Prefixo desviante	Score de conformidade

Ideia-chave A predição deve corresponder a uma decisão operacional e a um momento em que alguém ainda possa agir.

Prefixos, rótulos e pontos de predição




Defina

- ▶ Regra e corte do prefixo
- ▶ Frequência de predição
- ▶ Horizonte do rótulo

Evite

- ▶ Features calculadas após o corte
- ▶ Rótulos indisponíveis na operação
- ▶ Prefixos duplicados entre divisões

Separe por tempo e agrupe por caso



- ▶ Atribua cada caso e todos os seus prefixos a exatamente uma divisão.
- ▶ Ajuste codificadores, imputadores, escalonadores e vocabulários apenas nos dados de treino.
- ▶ Prefira avaliação temporal quando o modelo implantado prevê casos futuros.
- ▶ Mantenha clientes, pedidos ou objetos relacionados juntos quando houver dependência.
- ▶ Reserve o período de teste para uma estimativa final após a seleção.

Caminhos comuns de vazamento

Vazamento do futuro

- ▶ Atributos finais do caso em um prefixo
- ▶ Número total de eventos ou duração final
- ▶ Recurso ou status posterior ao resultado

Vazamento entre divisões

- ▶ Prefixos de um caso em várias divisões
- ▶ Divisão aleatória no nível dos eventos

Vazamento no pré-processamento

- ▶ Normalização ou imputação global
- ▶ Variantes construídas com todos os períodos
- ▶ Modelo de descoberta ajustado nos casos de teste

Vazamento operacional

- ▶ Feature indisponível no momento da pontuação
- ▶ Definição do rótulo muda após a implantação

Avalie além da acurácia preditiva

Discriminação

AUC, PR-AUC,
MAE, concordance

Calibração

Confiabilidade,
Brier score,
cobertura de
intervalos

Antecedência

Antecedência,
estabilidade entre
prefixos

Utilidade

Custo, carga de
trabalho, atraso
evitado, valor da
decisão

Monitore também:

- ▶ Desempenho por coorte e estado do processo
- ▶ Drift de features, rótulos e processo
- ▶ Volume de alertas, carga de falsos alarmes e capacidade de intervenção

Padrões de integração: mineração de processos + ML


A mineração de processos informa o ML

Variantes, estado do modelo, alinhamentos, conformidade, retrabalho e transferências tornam-se features ou coortes.

O ML informa a análise de processos

Predições identificam prefixos de risco e revelam onde os erros se concentram no processo.

Ideia-chave Versione e monitore o mapeamento de eventos, o modelo de processo, a codificação e o modelo preditivo como um único sistema analítico.



Uma cadeia de evidências para cada achado

1. **Pergunta:** qual decisão está em jogo?
2. **Observação:** qual padrão foi medido?
3. **Interpretação:** qual mecanismo pode explicá-lo?
4. **Validação:** o que especialistas do domínio ou outros dados confirmaram?
5. **Ação:** qual mudança deve ser testada?
6. **Métrica:** como saberemos se funcionou?

Ideia-chave Separe observação de interpretação. Isso torna a análise mais fácil de questionar, melhorar e confiar.

Comunique bem um achado

Comece por

- ▶ Consequência operacional
- ▶ Magnitude e população afetada
- ▶ Evidência visual concisa
- ▶ Próxima ação recomendada

Sempre inclua

- ▶ Escopo dos dados
- ▶ Premissas principais
- ▶ Incerteza
- ▶ Alternativas importantes

Padrão de título

O que acontece + onde + impacto: “Ciclos de esclarecimento adicionam 4,1 dias aos pedidos personalizados do canal parceiro.”

Checklist de reprodutibilidade

- ▶ Código versionado de extração e transformação
- ▶ Dicionário de dados e semântica dos eventos
- ▶ Parâmetros fixos e versões dos pacotes
- ▶ Figuras e tabelas determinísticas
- ▶ Exclusões e filtros documentados
- ▶ Artefatos de modelo armazenados
- ▶ Log de decisões e validações
- ▶ Estratégia de compartilhamento sensível à privacidade

Discussão Outro analista conseguiria reproduzir seu achado central sem perguntar onde você clicou?

Oportunidades de pesquisa

Dados de eventos mais ricos

- ▶ Logs de eventos multimodais
- ▶ Abstração automatizada de eventos
- ▶ Eventos centrados em objetos, em streaming e incertos

Análises mais ricas

- ▶ Aprendizado de representações multimodais
- ▶ Mineração causal de processos
- ▶ Monitoramento prescritivo
- ▶ Análises com preservação de privacidade

Logs de eventos multimodais

Alinhe eventos estruturados com payloads como texto livre, documentos, imagens, áudio e fluxos de sensores, preservando tempo, proveniência e regras de acesso.

Ideia-chave Cada modalidade deve acrescentar evidência de processo válida, oportuna e governável.

Projeto final: estudo de processo ponta a ponta

Análise obrigatória

- ▶ Escopo e perguntas analíticas
- ▶ Semântica dos eventos e relatório de qualidade
- ▶ Representação, flattening e codificação
- ▶ Exploração, desempenho e descoberta
- ▶ Vetor de qualidade e comparação pela fronteira de Pareto
- ▶ Análise de conformidade ou desvios

Argumentação obrigatória

- ▶ Um achado validado
- ▶ Baseline preditivo quando relevante
- ▶ Divisão e avaliação sem vazamento
- ▶ Uma hipótese de melhoria
- ▶ Limitações éticas e analíticas
- ▶ Código e artefatos reproduzíveis
- ▶ Apresentação orientada aos stakeholders

Avaliação do projeto final

Dimensão	Evidência de um trabalho sólido
Pergunta e escopo	Decisão específica, noção de caso coerente e limites explícitos
Representação	Semântica validada, flattening e codificação justificados
Qualidade do modelo	Vetores completos de métricas, análise de Pareto e regra de seleção estável
Predição	Divisão sem vazamento, erros calibrados e baseline operacional
Interpretação	Achados distinguem evidência de explicação
Reprodutibilidade	A análise executa das entradas documentadas até as saídas
Comunicação	Consequência, incerteza e próxima ação estão claras

A disciplina do analista

1. Questione a semântica dos eventos.
2. Torne explícitas as escolhas de representação.
3. compare vetores de qualidade, não uma única pontuação.
4. Previna vazamento antes do treinamento.
5. Transforme achados e previsões em ações testáveis.

Ideia-chave A habilidade mais importante em mineração de processos é saber o que os dados permitem afirmar.

Perguntas tornam-se evidências.

Evidências tornam-se melhores decisões de processo.

Referências — livro-texto principal

Referência principal

van der Aalst, W.M.P. (2016). *Process Mining: Data Science in Action* (2ª ed.). Springer.

Este livro-texto, escrito pelo fundador da área de mineração de processos, é a referência principal para os conceitos abordados ao longo do curso: semântica do log de eventos, descoberta de processos, verificação de conformidade e aprimoramento de processos.

Referências — artigos selecionados

1. de Alvarenga, S.C., Barbon Jr., S., Miani, R.S., Cukier, M., Zarpelão, B.B. (2018). Process mining and hierarchical clustering to help intrusion alert visualization. *Computers & Security*, 73, 474–491. <https://www.sciencedirect.com/science/article/pii/S0167404817302584>
2. Ceravolo, P., Tavares, G.M., Barbon Jr., S., Damiani, E. (2020). Evaluation Goals for Online Process Mining: A Concept Drift Perspective. *IEEE Transactions on Services Computing*. <https://ieeexplore.ieee.org/abstract/document/9124702>
3. Tavares, G.M., Oyamada, R.S., Barbon Jr., S., Ceravolo, P. (2023). Trace encoding in process mining: A survey and benchmarking. *Engineering Applications of Artificial Intelligence*, 126, 107028. <https://www.sciencedirect.com/science/article/pii/S0952197623012125>
4. da Silva, M.C., Tavares, G.M., Gritti, M.C., Ceravolo, P. (2023). Using Process Mining to Reduce Fraud in Digital Onboarding. *FinTech*, 2(1), 120–137. <https://www.mdpi.com/2674-1032/2/1/9>